

1 年間のロードマップ

1. 教師データの収集とローカル LLM の基盤作成 (2026 年 4 月～2026 年 6 月)

Wazuh およびハニーポットを主軸とし、ローカル LLM に学習をさせる教師データを収集、精査する。

1.1 自動分析パイプラインの構築：

Wazuh から出力されるセキュリティログをスクリプトでログ抽出の間隔を変化させながら、Gemini が攻撃の全体をより捉えやすいようなプロンプトを考え、プロンプトも変化させながら詳細なトリアージレポートを生成させる

1.2 人間の評価と AI の評価の比較：

Wazuh アーカイブや ModeSecurity の監査ログを実際に関連し、生成されたレポート比べ評価する。その際、過検知や見落としを記録し、正解率を表にまとめ数値化する。

2. 教師データの質の担保と自動化の安定 (2026 年 7 月～2026 年 9 月)

前段階で得た結果に基づき、次年度の学習に効果的な質の高いデータセットのみを抽出・蓄積する。

2.1 フィードバックの同期自動化の実装：

人間が正しいと判断したレポートのみを教師データ用リポジトリに分類する仕組みの構築をする。

2.2 データセットの構造化：

ローカル LLM の学習に最適な指示、ログデータそして正解レポートの JSON 形式で保存の自動化をする。

3. ローカル LLM の追加学習 (2026 年 10 月～2026 年 12 月)

これまでに収集・選別した高品質データを用いて学習を行う。

3.1 QLoRA による特化学習：

既存のライブラリを活用し、Llama3 に対して自作のデータセットで追加学習を行う。

3.2 精度評価の再実施：

学習後のローカル LLM にテスト用のログを入力し、Gemini の回答と比較してどの程度アナリストとしての思考がついたのかを検証する。

4. 高対話型ハニーポットの統合と IoC 自律抽出の実装（2027 年 1 月～2027 年 3 月）

特化学習を終えたローカル LLM を実戦投入し、より高度な脅威（侵入後の挙動）を解析する体制へ移行する。

4.1 Cowrie の導入とログ連携：

攻撃者を入り口で弾くのではなく、意図的に隔離環境へ誘導する高対話型ハニーポット（Cowrie）を構築し、Wazuh と統合する。これにより、攻撃者が侵入後に実行する難読化コマンドなどの深い攻撃ログを収集可能にする。

4.2 ローカル LLM による IoC の自律抽出：

セキュリティアナリストとしての思考を学習したローカル LLM に対し、Cowrie で観測された難読化スクリプトを入力する。外部 API（Gemini）に依存しない閉鎖的な環境下で、IoC を高精度かつ全自動で抽出させる。